

García Rodríguez Lázaro Isaac

El video "Ludov Peres: Some Highlights from the History of Probability"

La conferencia presenta como la probabilidad pasó de estudiar juegos de azar a convertirse en una teoría matemática más profunda, conectada con análisis matemático, combinatorio, algoritmos y procesos estocásticos.

Un punto importante con el que se inicia la plática fue "La ley de los grandes números" asociada con Borel que explica por qué al repetir muchas veces un experimento aleatorio, el promedio observado se acerca al valor esperado. Además se menciona la formalización moderna de la probabilidad con Kolmogorov, quien dio las bases axiomáticas rigurosas a la teoría.

Adicionalmente se habla de la caminata aleatoria estudiada por Pólya, y de su conexión con la recurrencia y transiencia. En dimensiones bajas, una caminata aleatoria puede regresar muchas veces al origen, mientras que en dimensiones altas puede alejarse. Esto conecta directamente con cadenas de Markov.

El movimiento browniano, relacionado con Wiener y Lévy, el cual describe trayectorias aleatorias continuas y sirve como límite de caminatas aleatorias rescaladas. De ahí surgen herramientas modernas como **martingales**, **integrales estocásticas** y **cálculo de Itô**.

La conferencia también mencionó avances más recientes como SLF, campos gaussianos libres y vínculos con física matemática, mostrando que la probabilidad no solo sirve para calcular chances, sino para estudiar estructuras complejas y fenómenos aleatorios profundos.

Ahora bien para la primera simulación la tenemos enfocada en la **ley de los grandes números**.

Esta simulación muestra que al lanzar una moneda muchas veces, la proporción de caras se acerca a 0.5.

```
import numpy as np
import matplotlib.pyplot as plt

n = 10000
lanzamientos = np.random.choice([0, 1], size=n) # 1 = cara, 0 = cruz

promedios = np.cumsum(lanzamientos) / np.arange(1, n + 1)

plt.figure(figsize=(8, 4))
plt.plot(promedios, label="Promedio acumulado")
plt.axhline(0.5, linestyle="--", label="Valor esperado = 0.5")
plt.xlabel("Número de lanzamientos")
plt.ylabel("Proporción de caras")
plt.title("Ley de los Grandes Números")
plt.legend()
plt.grid(True)
plt.show()
```

Al inicio el promedio capta mucho, pero conforme aumentan los lanzamientos, se estabiliza cerca de 0.5

Ahora bien, también tomando en cuenta que se habló del **Teorema Central del Límite** se realizó la simulación.

Con muchas muestras y calculamos sus promedios. Aunque los datos originales no sean normales, los promedios tienden a formar una campana

```
import numpy as np
import matplotlib.pyplot as plt

num_muestras = 5000
tamano_muestra = 50

promedios = []

for _ in range(num_muestras):
    muestra = np.random.exponential(scale=1, size=tamano_muestra)
    promedios.append(np.mean(muestra))

plt.figure(figsize=(8, 4))
plt.hist(promedios, bins=40, density=True, edgecolor="black")
plt.xlabel("Promedio muestral")
plt.ylabel("Densidad")
plt.title("Teorema Central del Límite")
plt.grid(True)
plt.show()
```

Se utilizó una distribución exponencial pero con así los promedios muestrales se parecen a una distribución normal

Si tomamos ahora las caminatas aleatorias en $\mathbb{Z}$ la siguiente simulación representa una caminata aleatoria simple, uno de los objetos más importantes en procesos estocásticos

```
import numpy as np
import matplotlib.pyplot as plt

n = 1000
pasos = np.random.choice([-1, 1], size=n)
posicion = np.cumsum(pasos)

plt.figure(figsize=(8, 4))
plt.plot(posicion)
plt.axhline(0, linestyle="--")
plt.xlabel("Tiempo")
plt.ylabel("Posición")
plt.title("Caminata aleatoria simple en  $\mathbb{Z}$ ")
plt.grid(True)
plt.show()
```

La posición cambia al azar en cada paso. Este modelo se relaciona con Pólya, recurrencia, transiencia y cadenas de Markov.

Adicionalmente sabemos que para la **aproximación al movimiento browniano**, puede entenderse como el límite de una caminata aleatoria reescalaada.

```

import numpy as np
import matplotlib.pyplot as plt

n = 5000
pasos = np.random.choice([-1, 1], size=n)
caminata = np.cumsum(pasos)

tiempo = np.linspace(0, 1, n)
browniano_aprox = caminata / np.sqrt(n)

plt.figure(figsize=(8, 4))
plt.plot(tiempo, browniano_aprox)
plt.xlabel("Tiempo")
plt.ylabel("Posición reescalada")
plt.title("Aproximación al Movimiento Browniano")
plt.grid(True)
plt.show()

```

Al aumentar el número de pasos y reescalar la caminata, la trayectoria se parece al movimiento browniano

Pero ¿Qué es el movimiento browniano?

Es un proceso estocástico continuo que modela el movimiento aleatorio de partículas suspendidas en un fluido

El movimiento browniano representa un movimiento

- Completamente aleatorio
- Continuo en el tiempo
- Sin direcciones fijas
- Con fluctuaciones gaussianas

En conclusión:

El video muestra que la probabilidad moderna ha evolucionado desde ideas intuitivas como promedios y azar, hasta herramientas avanzadas como **martingales**, **movimiento browniano**, **cadena de Markov**, **SLB** y **modelos de física estadística**. Las simulaciones anteriores representan algunos de los conceptos principales: **estabilidad de promedios**, **normalidad aproximada**, **camminos aleatorios** y **movimiento browniano**.

Con esto podemos ver como conceptos básicos de probabilidad estadística pueden crecer en temas más complejos como los antes mencionados, teniendo así teorías y conceptos más interesantes.

Además el movimiento browniano es uno de los modelos fundamentales en procesos estocásticos ya que permite describir fenómenos aleatorios que evolucionan de manera continua en el tiempo.

